

TRAINING

Come nasce un modello di AI? Ecco tutte le fasi, facciamo chiarezza

Home > Intelligenza Artificiale



Partecipa al dibattito

I modelli AI generativa nascono da una filiera tecnica sempre più articolata: pre-training su enormi basi dati, fine-tuning supervisionato, preferenze umane, reinforcement learning, reasoning training e test di sicurezza. Vediamo nel dettaglio cosa porta ai modelli che tutti noi usiamo

Pubblicato il 23 giu 2026

 Aggiungi tra i preferiti su Google

Alessandro Longo

Direttore AI4business.it e Agenda Digitale

 Chiedi all'AI



OpenAI
GPT
ChatGPT



ANTHROPIC
Claude



Google
Gemini



xAI
Grok



Meta
Llama



MISTRAL
AI_



DeepSeek



Alibaba
Qwen



Microsoft
Copilot

Chiedi all'AI

Riassumi questo articolo

Approfondisci con altre fonti

Punti chiave

- Pipeline: il pre-training costruisce conoscenza generale; il fine-tuning supervisionato, il reward model e tecniche come RLHF o DPO orientano il comportamento.
- Ruolo umano: i dati sintetici e la distillazione accelerano il training, ma annotatori, feedback umano e verifiche rimangono imprescindibili.
- Scala e costi: architetture Transformer e MoE, cluster GPU/TPU e spese milionarie; per le imprese è preferibile RAG, fine-tuning mirato e governance.

Riassunto generato con AI

C'

è tanta confusione sui processi che portano alla nascita di un modello AI.



È noto ormai che c'è un **training basato su dati**. Meno noto che questo training ha diverse fasi, alcune massive, altre specialistiche e di dettaglio, con diversi ruoli per l'essere umano, ancora non eludibile. Ancora non siamo entrati insomma nell'addestramento automatico totale di un modello, alba di un ipotetico **recursive self improvement infinito**.

Sempre più spesso si usano dati sintetici per il training, è vero, ma con un ruolo persistente dell'umano. Se ne parla in una **recente scoperta del New Scientist**: alcuni addestratori invece di generare dati umani per il training hanno usato un chatbot. Un problema: a conferma che l'umano non può essere sostituito dal sintetico tout court.

La filiera che porta da un **base model** a un prodotto come **GPT, Claude, Gemini** o **Grok** è ormai abbastanza riconoscibile, anche se ogni laboratorio usa ricette, nomi e pesi diversi.

Le fasi principali allora sono

- pre-training,
- fine-tuning supervisionato,
- raccolta di preferenze,
- reward modeling,
- reinforcement learning,
- training sul ragionamento.
- test di sicurezza
- e post-training continuo.

Per un costo totale di decine di milioni di dollari.

Vediamo nel dettaglio.

Modello	Costo training stimato	Fonte
DeepSeek-V3	5,576 milioni di dollari	DeepSeek, dato dichiarato



Modello	Costo training stimato	Fonte
GPT-4	circa 79 milioni di dollari	Stanford AI Index 2025 / Epoch AI
Gemini 1.0 Ultra	circa 192 milioni di dollari	Stanford AI Index 2025 / Epoch AI
Llama 3.1 405B	circa 170 milioni di dollari	Stanford AI Index 2025 / Epoch AI
Grok-2	circa 107 milioni di dollari	Stanford AI Index 2025 / Epoch AI

Indice degli argomenti: ▲

Il pre-training: dove il modello impara lingua, codice e conoscenza generale

Architettura e infrastruttura: Transformer, MoE e cluster distribuiti

Il fine-tuning supervisionato: il modello diventa un assistente

Reward model e preferenze: come si misura una buona risposta

RLHF, DPO, GRPO: i diversi approcci al post-training

Constitutional AI e feedback da altri modelli

Dati sintetici e distillazione: quando il modello addestra altri modelli

Reasoning training: il modello impara a spendere calcolo mentre risponde

Safety, valutazioni e post-training continuo

Dove nasce davvero il “sapere” del modello

Il pre-training: dove il modello impara lingua, codice e conoscenza generale

Il **pre-training** è la fase in cui il modello assorbe la maggior parte delle proprie capacità linguistiche e conoscenze generali. **OpenAI**, nel **GPT-4 Technical Report** del 2023, descrive GPT-4 come un modello Transformer pre-addestrato per prevedere il token successivo in un documento. È la formulazione tecnica del meccanismo di base: dato un contesto, il modello stima quale unità linguistica abbia più probabilità di venire dopo.



AI nel customer service: scopri come superare i progetti pilota e generare ROI

Intelligenza Artificiale # Marketing



[Leggi l'informativa sulla privacy](#)

E-mail aziendale*

☐ **Acconsento alla comunicazione dei miei dati a [terzi](#) affinché li trattino per proprie finalità di marketing tramite modalità automatizzate e tradizionali di contatto.**

SCARICA ORA

La scala è enorme. Meta, nel lancio di [Llama 3.1 405B](#), ha indicato oltre 15 trilioni di token e più di 16 mila GPU Nvidia H100 per l'addestramento del suo modello più grande. DeepSeek, nel technical report di DeepSeek-V3, dichiara 14,8 trilioni di token, 2,788 milioni di ore GPU H800 e un costo



della sola fase ufficiale di training stimato in **5,576 milioni di dollari**, esclusi esperimenti preliminari e ricerca.

Il pre-training richiede anche una pipeline di preparazione dei dati: raccolta, deduplicazione, classificazione, filtri di qualità, filtri di sicurezza, tokenizzazione, bilanciamento tra lingue e domini. **Google**, nel [report tecnico](#) Gemini 2.5, indica per la serie 2.5 una base di pre-training multimodale con documenti web pubblici, codice, immagini, audio e video, con cutoff gennaio 2025 per Gemini 2.5. xAI, nella [model card di Grok 4](#), descrive una ricetta con dati web pubblici, dati prodotti da terze parti, dati di utenti o contractor e dati generati internamente, filtrati con deduplicazione e classificazione.

Architettura e infrastruttura: Transformer, MoE e cluster distribuiti

Il pre-training non è solo una questione di dati. Conta anche l'architettura. Molti modelli restano basati su Transformer, ma cresce l'uso di architetture **mixture-of-experts**, che attivano solo una parte dei parametri per ciascun token. Google descrive Gemini 2.5 come una famiglia di Transformer sparse MoE multimodali; xAI aveva già rilasciato [Grok-1](#) come modello MoE da **314 miliardi di parametri**, con il **25% dei pesi attivi** per token.

La scala introduce problemi ingegneristici propri: guasti hardware, instabilità numeriche, errori silenziosi, ripartenze, sincronizzazione tra cluster. Nel report Gemini 2.5, Google spiega di avere addestrato la famiglia su architettura **TPUv5p**, con training data-parallel sincro su più pod da **8.960 chip** distribuiti su più data center. Lo stesso report indica che, durante il run, il **93,4% del tempo** è stato speso in computazione TPU e che circa lo **0,25% degli step** è stato rieseguito per sospetta corruzione silenziosa dei dati.

Secondo [Epoch AI](#), il compute usato per addestrare i frontier language model cresce di circa **5 volte l'anno** 

costo di training dei modelli di frontiera, sempre secondo Epoch AI, cresce di circa **3,5 volte l'anno**. Lo [Stanford AI Index 2025](#), usando stime Epoch, colloca il costo di training di GPT-4 intorno a **79 milioni di dollari** e quello di Llama 3.1 405B intorno a **170 milioni di dollari**.

Questi numeri spiegano perché pochi soggetti addestrano modelli di frontiera da zero. Per imprese e sviluppatori, la scelta più frequente è diversa: usare un modello già addestrato, adattarlo con fine-tuning, [retrieval augmented generation \(RAG\)](#), dati proprietari, controlli applicativi e governance.

La scala dei training pubblicamente documentati mostra bene la distanza tra modelli di frontiera e adattamenti enterprise.

Modello o fonte	Dato rilevante	Che cosa mostra
Llama 3.1 405B, Meta 2024	oltre 15 trilioni di token, oltre 16 mila H100	scala del pre-training open-weight di frontiera
DeepSeek-V3, DeepSeek 2024	14,8 trilioni di token, 2,788 milioni di ore GPU H800	efficienza di training e ruolo dell'ottimizzazione
GPT-4, stima Stanford AI Index 2025/Epoch	circa 79 milioni di dollari	costo stimato dei modelli chiusi di frontiera
Llama 3.1 405B, stima Stanford AI Index 2025/Epoch	circa 170 milioni di dollari	aumento dei costi per i modelli più grandi
InstructGPT, OpenAI 2022	circa 13 mila prompt SFT, 33 mila prompt reward model, 31 mila prompt PPO	dimensione relativamente piccola ma decisiva del post-training

Il fine-tuning supervisionato: il modello diventa un assistente

Un base model sa completare testo, ma non necessariamente rispondere bene a una domanda. Può continuare un prompt, imitare stili, produrre frammenti incoerenti o ignorare vincoli. Il **supervised fine-tuning**, spesso indicato come SFT, serve a insegnare il formato dell'interazione: istruzione dell'utente, risposta utile, stile conversazionale, ecc.  dell'output.

Nel paper OpenAI [Training language models to follow instructions with human feedback](#), pubblicato a NeurIPS 2022, la pipeline InstructGPT parte da dimostrazioni scritte da annotatori. Il dataset SFT contiene circa **13 mila prompt** di training. È piccolo rispetto ai trilioni di token del pre-training, ma cambia in modo sostanziale il comportamento del modello: gli insegna che cosa significa rispondere come assistente, non solo completare testo.

Questa fase oggi può essere umana, sintetica o ibrida. Nei modelli più avanzati gli esempi non sono soltanto domande e risposte generiche: includono codice, ragionamento matematico, analisi di documenti lunghi, uso di strumenti, chiamate a funzioni, risposta multimodale, policy di sicurezza, casi limite e scenari avversariali.

Reward model e preferenze: come si misura una buona risposta

Dopo il fine-tuning supervisionato entra in gioco il problema più difficile: definire che cosa sia una risposta migliore. Una risposta può essere grammaticalmente corretta ma incompleta, sicura ma evasiva, dettagliata ma sbagliata, brillante ma non aderente alla richiesta. Per questo molti laboratori raccolgono **preferenze umane**.

Nella pipeline InstructGPT, OpenAI ha usato circa **33 mila prompt** per addestrare un reward model e circa **31 mila prompt** per la fase PPO. Gli annotatori confrontavano più risposte allo stesso prompt; il reward model imparava a stimare quale risposta sarebbe stata preferita. Lo stesso paper indica che il team di annotazione principale era composto da circa **40 contractor** e che, nelle valutazioni interne, le risposte del modello InstructGPT da 1,3 miliardi di parametri erano preferite a quelle di GPT-3 da 175 miliardi, nonostante una dimensione circa 100 volte inferiore.

Il reward model introduce però un **problema di ottimizzazione** per massimizzare il punteggio invece di



come **reward hacking**, è uno dei motivi per cui il post-training moderno combina più segnali: preferenze umane, valutazioni automatiche, benchmark, test avversariali, ricompense verificabili e controlli di policy.

RLHF, DPO, GRPO: i diversi approcci al post-training

Per affinare ulteriormente, il metodo più noto è il **RLHF, reinforcement learning from human feedback**. Il modello genera risposte, il reward model assegna un punteggio, l'algoritmo di reinforcement learning modifica i parametri per rendere più probabili le risposte valutate meglio.

Storicamente, l'algoritmo di riferimento è stato **PPO**, Proximal Policy Optimization.

Negli ultimi anni sono cresciute alternative più semplici o più efficienti. La **DPO**, Direct Preference Optimization, proposta da **Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning e Chelsea Finn** nel paper **Direct Preference Optimization: Your Language Model is Secretly a Reward Model**, elimina il reward model esplicito e l'ottimizzazione RL tradizionale, trasformando le preferenze in una loss di classificazione più diretta.

La **GRPO**, Group Relative Policy Optimization, introdotta nel paper DeepSeekMath **Pushing the Limits of Mathematical Reasoning in Open Language Models**, riduce il peso del modello critico usato in PPO stimando la baseline dai punteggi relativi di un gruppo di risposte. In DeepSeekMath, l'approccio ha migliorato compiti matematici come GSM8K, passato da **82,9% a 88,2%**, e MATH, passato da **46,8% a 51,7%** nella fase RL indicata dagli autori.

Il punto operativo è che il post-training non è più una fase unica. È una combinazione di ricette: SFT, reward model, RLHF, DPO, GRPO, rejection sampling, reward verificabili, giudici generato da modelli.



Constitutional AI e feedback da altri modelli

Anthropic ha reso popolare un approccio diverso con la **Constitutional AI**. Nel paper del 2022 [Constitutional AI: Harmlessness from AI Feedback](#), Yuntao Bai e coautori descrivono un metodo in cui il modello produce critiche e revisioni delle proprie risposte usando una lista di principi, poi un modello valuta coppie di risposte sulla base di quei principi. La fase successiva usa reinforcement learning from AI feedback, cioè **RLAIF**.

Nella [system card di Claude Opus 4 e Claude Sonnet 4](#), Anthropic indica che i modelli sono stati pre-addestrati su grandi dataset diversi e poi orientati a essere helpful, honest and harmless con tecniche che includono human feedback, Constitutional AI e training di tratti caratteriali selezionati. Per Claude 4, la system card cita anche un **extended thinking mode**, in cui il modello può spendere più tempo nel ragionamento prima della risposta.

Il vantaggio del feedback generato da AI è la scalabilità. Il limite è la dipendenza da principi, giudici e controlli che devono essere progettati con molta attenzione. Un modello che valuta un altro modello può amplificare errori, preferenze implicite o scorciatoie, se la pipeline non è verificata con dati indipendenti e valutazioni umane.

Dati sintetici e distillazione: quando il modello addestra altri modelli

I **dati sintetici** sono diventati una componente sempre più importante. Un modello forte può generare esercizi, soluzioni, esempi di dialogo, codice, spiegazioni, casi limite e dataset di ragionamento. Questi dati vengono filtrati, valutati e riutilizzati per addestrare o rifinire altri modelli.

Google, nel report Gemini 2.5, descrive per i modelli più piccoli della famiglia l'uso della **distillazione**: un modello *teacher* addestra modelli più economici da servire. Q



mercato enterprise, perché molti casi d'uso non richiedono sempre il modello più grande. Un modello più piccolo, distillato e ben specializzato può offrire latenza inferiore, costi più prevedibili e maggiore controllabilità.

DeepSeek-R1, nel paper [Incentivizing Reasoning Capability in LLMs via Reinforcement Learning](#), mostra un'altra traiettoria: le capacità di ragionamento possono essere incentivate con reinforcement learning su compiti verificabili, riducendo la dipendenza da traiettorie di ragionamento annotate da esseri umani. Gli autori descrivono l'emergere di pattern come auto-verifica, riflessione e adattamento dinamico della strategia.

Reasoning training: il modello impara a spendere calcolo mentre risponde

La differenza più recente tra modelli “chat” e modelli “reasoning” riguarda il calcolo usato in inferenza. I primi tendono a produrre una risposta direttamente. I secondi sono addestrati a usare più passaggi interni prima di rispondere, soprattutto su matematica, coding, pianificazione, analisi multi-step e uso di strumenti.

OpenAI, nella [system card di o1](#), descrive la serie o1 come addestrata con reinforcement learning su larga scala per ragionare usando chain-of-thought. Nel contributo su [deliberative alignment](#), OpenAI indica che i modelli o-series vengono addestrati a ragionare su specifiche di sicurezza interpretabili prima di rispondere.

Google, nel report Gemini 2.5, afferma che i modelli Gemini Thinking sono addestrati con reinforcement learning per usare compute aggiuntivo in inferenza. Il report indica che questi modelli possono spendere anche **decine di migliaia di forward pass** durante una fase di thinking prima della risposta. Qui cambia il modello economico: non conta solo quanto costa addestrare il sistema, ma anche quanta compute serve per una risposta difficile.



Safety, valutazioni e post-training continuo

Prima del rilascio entrano in gioco red teaming, benchmark, test di policy, valutazioni su cybersecurity, rischio biologico, allucinazioni, bias, prompt injection, tool use e comportamento agentic. Anthropic, nella system card di Claude 4, documenta test pre-deployment su violazioni della usage policy, reward hacking, sicurezza agentic e rischi di disallineamento.

Google, nel report Gemini 2.5, include valutazioni su cybersecurity, CBRN, **machine learning** R&D e deceptive alignment. xAI, nella model card di Grok 4, indica reinforcement learning con human feedback, reward verificabili e model grading, oltre al fine-tuning supervisionato di capacità specifiche.

Dopo il rilascio, il lavoro continua. I laboratori raccolgono segnali da benchmark, feedback degli utenti, bug report, valutazioni di sicurezza, attacchi riusciti, errori ricorrenti e casi di allucinazione. Questi dati alimentano nuovi cicli di post-training. Per questo la stessa famiglia di modelli può cambiare comportamento tra versioni successive anche quando il nome commerciale sembra simile.

Lo **Stanford AI Index 2025** segnala anche l'impatto ambientale della scala: le emissioni stimate per il training passano da **588 tonnellate di CO2 equivalente** per GPT-3 nel 2020 a **5.184 tonnellate** per GPT-4 nel 2023 e **8.930 tonnellate** per Llama 3.1 405B nel 2024, secondo la sezione Research and Development del report. Il training resta solo una parte del costo complessivo: quando un modello viene usato da milioni di utenti, l'inferenza diventa una voce permanente.

Dove nasce davvero il “sapere” del modello

Insomma: la conoscenza fattuale, le competenze linguistiche, la programmazione e una parte delle capacità di ragionamento nascono soprattutto nel pre-training.



Il comportamento da assistente nasce invece nel post-training.

In altre parole:

- il pre-training costruisce il modello generale;
- il fine-tuning gli insegna a rispondere;
- le preferenze e il reinforcement learning gli insegnano quali risposte sono migliori;
- il reasoning training gli insegna a usare più calcolo sui problemi complessi;
- i test di sicurezza e il post-training continuo cercano di correggere errori, rischi e comportamenti indesiderati.

Per le imprese, questa distinzione è decisiva. Addestrare da zero un modello di frontiera è un'attività industriale da grandi laboratori.

Preparare un sistema AI affidabile per un processo aziendale richiede invece un'altra catena: scelta del modello, dati proprietari puliti, retrieval, fine-tuning mirato quando serve, valutazioni di qualità, controlli di sicurezza, monitoraggio e governance.

Un tema di cui ci occupiamo spesso qui.

WEBINAR

16 lug 2026 alle 15:00

Quante ore perdi ogni settimana nel caos documentale? Scopri come evitarlo

 Amministrazione/Finanza/Controllo  Gestione Dati





Inizia tra 17 gg 6 ore 25 min 32 sec

Iscriviti al Webinar

Strategie multi-AI: integrare diversi modelli di calcolo

@RIPRODUZIONE RISERVATA

Valuta la qualità di questo articolo





Alessandro Longo

Direttore AI4business.it e Agenda Digitale

Leggi anche:

- [I World model: tutto sulla nuova frontiera AI che può cambiare il mondo](#)
- [Fine-tuning: come personalizzare i modelli AI per il business](#)
- [ChatGPT: come funziona il chatbot di OpenAI](#)

Partecipa alla community



Inserisci il tuo commento

B *I* U



Nome

Email*

Invia commento

0 COMMENTI

Italia Digitale post-PNRR: scenari, sfide e opportunità del nuovo ecosistema pubblico

31 May 2026



Scaricalo gratis!

DOWNLOAD

Il retail in Italia: crescita digitale e trasformazione forzata

15 Mag 2026

Scaricalo gratis!

DOWNLOAD

Canali




AI Generativa



Intelligenza Artificiale

Articoli correlati



ANALISI

I World model: tutto sulla nuova frontiera AI che può cambiare il mondo

13 Feb 2026

di Alessandro Longo




APPROFONDIMENTO

Fine-tuning: come personalizzare i modelli AI per il business

15 Gen 2026

di Fabio Lalli

Condividi ➔






GUIDA

Il retail in Italia: crescita digitale e trasformazione forzata

15 Mag 2026



Scaricalo gratis!

DOWNLOAD

