


PIPELINE PER ELABORAZIONE DATI

Pipeline di Elaborazione Dati

Una **pipeline** è un processo strutturato composto da più fasi, attraverso cui i dati vengono raccolti, trasformati, analizzati e archiviati. È il cuore del lavoro di un data scientist.

Fasi principali:

1. **Acquisizione**
2. **Pulizia**
3. **Trasformazione**
4. **Analisi**
5. **Immagazzinamento**




Acquisizione dei dati

In questa fase si raccolgono i dati da una o più **fonti**: API, file, database, web scraping.

Esempio:

- Un'azienda raccoglie i dati degli ordini dei clienti da:
- un file Excel (ordini online),
- un database aziendale (ordini da negozio fisico),
- e un'API del corriere (stato delle spedizioni).




Pulizia dei dati

I dati grezzi spesso contengono errori, duplicati o campi mancanti. La pulizia consiste nel **correggere, filtrare o eliminare** le anomalie.

Esempio:

- Alcuni clienti hanno compilato il campo "email" con valori sbagliati o mancanti.
- Altri ordini sono duplicati o hanno date non valide.

Questi problemi vengono rilevati e sistemati.




Trasformazione dei dati

I dati vengono **convertiti, normalizzati o arricchiti**, per essere pronti all'analisi. È qui che si prepara il dataset finale.

Esempio:

- Le date degli ordini vengono convertite nel formato corretto.
- Si crea un nuovo campo:
"tempo di consegna" = data di consegna – data di ordine.
- I valori monetari vengono convertiti tutti in euro.



Analisi dei dati


In questa fase si esplorano e si analizzano i dati per **scoprire pattern, tendenze o anomalie**, spesso anche con visualizzazioni.

Esempio:

L'azienda vuole sapere:

- Qual è il mese con più ordini?
- Quali prodotti sono più richiesti?
- Quanto tempo ci mettono mediamente le consegne?

Queste informazioni emergono con tabelle, grafici e statistiche descrittive.



Immagazzinamento dei dati

Una volta elaborati, i dati devono essere salvati per uso futuro, analisi successive o condivisione.

Esempio:

Il dataset finale viene:

- salvato in un file .csv per la reportistica,
- inserito in un database per dashboard in tempo reale,
- condiviso tramite un'applicazione web interna.

